

# **STK1100**

## **Oblig 1**

**Egil Furnes**  
**Studentnummer: 693784**

## Oppgave 1

a)

Det er til sammen 11 etasjer å velge mellom for første person, deretter 10, 9, og 8 etasjer. Sannsynligheten for at de 4 personene går av i hver sin etasje blir følgende muligheter delt på antall mulige etasjer, i dette tilfellet 54%.

$$\frac{11}{11} \cdot \frac{10}{11} \cdot \frac{9}{11} \cdot \frac{8}{11} = \frac{11 * 10 * 9 * 8}{11^4} = \frac{7920}{14641} \approx 0.540 = 54\%$$

b)

Her bruker jeg bare komplementet til sannsynligheten, hvor to eller flere personer går av i samme etasje bare er  $1 - 54\% = 46\%$ .

$$P^C = 1 - P = 1 - 0.54 = 0.46 = 46\%$$

c)

Benytter meg av en binomisk fordeling med grupper av 3 personer blant 4 mulige personer, og finner at det er totalt 4 slike grupper.

$$\binom{4}{3} = \frac{4!}{3!(4-3)!} = \frac{4 \cdot 3 \cdot 2 \cdot 1}{3 \cdot 2 \cdot 1 \cdot 1} = 4$$

d)

Sannsynligheten for at parallellkoblingen (1, 2) eller (4, 5) fungerer er  $1 - 0.05^2 = 0.9975$  og koblingen (3) er fortsatt 0.95. Dermed er sannsynligheten for at systemet som helhet fungerer følgende:

$$0.9975 \cdot 0.9975 \cdot 0.95 = 0.9452 \approx 94.5\%$$

## Oppgave 2

a)

Til tross for at anti-jukse-programmet avslører men tekst med 90% sannsynlighet, finner vi at bare 40% av tilfellene hvor det flagges for juks faktisk er det, grunnet den eksepsjonelt lave andelen av juksere i den totale befolkningen.

$$\frac{0.05 \cdot 0.90}{0.05 \cdot 0.90 + 0.95 \cdot 0.07} = 0.4035 \approx 40.4\%$$

b)

Bruker i dette tilfellet resultatet fra forrige deloppgave og setter opp en ligning, hvor vi finner at sannsynligheten for at programmet feilaktig fastlår at teksten er AI-generert må være så liten som 0.5% og ikke 10% som tidligere.

$$\frac{0.05 \cdot 0.90}{0.05 \cdot 0.90 + 0.95 \cdot x} = 0.90$$

$$x = \frac{0.05 * 0.90 - 0.05 * 0.90^2}{0.90 * 0.95} = \frac{1}{190} = 0.00526 \approx 0.5\%$$

Sannsynligheten for at programmet feilaktig anslår at teksten er AI-generert må være under 0.5% for at sannsynligheten i **a)** skal være over 90%.

## Oppgave 3

```

1 # laster inn pakker
2 library(tidyverse)
3 library(readr)
4
5 # leser inn data lokalt fra datamaskinen
6 data <- read_table("doedelighet.txt") %>%
7   mutate(menn = menn/1000,
8          kvinner = kvinner/1000)
9
10 # definerer en funksjon for at beregne gjennværende levealder
11 life <- function(qx){
12   n = length(qx)
13   lx = numeric(n); Lx <- numeric(n); Tx <- numeric(n); ex <- numeric
14     (n)
15   lx[1] = 1000000
16   for (i in 1:(n-1)) {
17     dx = lx[i]*qx[i]
18     lx[i+1] = lx[i]-dx
19     Lx[i] = lx[i]-0.5*dx
20   }
21   Lx[n] <- lx[n]*0.5
22   Tx <- rev(cumsum(rev(Lx)))
23   ex <- Tx/Lx
24   return(list(lx=lx, Lx=Lx, Tx=Tx, ex=ex))
25 }
26
27 men <- life(data$menn) %>% as_tibble()
28 women <- life(data$kvinner) %>% as_tibble()
29 aldre = c(0, 25, 50, 85)

```

a)

```

1 # a)
2 e_men = men$ex[aldre+1]
3 names(e_men) = paste("Age", aldre)
4 print("men:"); print(round(e_men,2))

```

```

[1] "men:"
Age 0 Age 25 Age 50 Age 85
81.32 56.79 32.79 6.22

```

Forventet gjennværende levealder for menn ved fødsel er med dette 81.32 år og følgende 56.79, 32.79 og 6.22 år for henholdsvis aldrene 25, 50 og 85.

**b)**

```

1 # b)
2 e_women = women$ex[aldre+1]
3 names(e_women) <- paste("Age", aldre)
4 print("women:"); print(round(e_women, 2))
5 print(tibble(Age=aldre, Men=round(e_men,2), Women=round(e_women,2),
6             Difference = round(e_women-e_men,2)))

```

```

[1] "women:"
Age 0 Age 25 Age 50 Age 85
84.69 59.97 35.59 7.28

```

Forventet gjenværende levealder for kvinner ved fødsel er med dette 84.69 år og følgende 59.97, 35.59 og 7.28 år for henholdsvis aldrene 25, 50 og 85 – altså noe lengre enn for menn!

```

# A tibble: 4 × 4
  Age    Men Women Difference
<dbl> <dbl> <dbl>      <dbl>
1     0  81.3  84.7         3.37
2    25  56.8  60.0         3.19
3    50  32.8  35.6          2.8
4    85   6.22  7.28         1.05

```

Her er utskrift av forskjellene, hvor forventet levealder for kvinner er noe høyere enn for menn.


**c)**

```

1 # c)
2 tibble(alder = min(data$alder):max(data$alder),
3       men = men$ex,
4       women = women$ex) %>%
5   ggplot(aes(x = alder)) +
6   geom_line(aes(y = men), col = "blue") +
7   geom_line(aes(y = women), col = "red") +
8   ggtitle(label = "Forventet gjenverande levealder",
9         subtitle = "Menn og kvinner") +
10  theme_minimal()

```

Fra plottet ser vi at kvinner og menn har en relativt forskjellig forventet levealder fra fødselen (hvor x-aksen alder er 0), deretter ser vi at disse sannsynlighetene konvergerer mot maksalderen som ligger på litt over 100 år.



## Oppgave 4

a)

Med  $q$  markører for 4 bokstaver har man  $4^q$  typer profiler.

Sannsynligheten for at en vilkårlig person har en spesifikk DNA profil  $\mathcal{S}$ .

For  $q = 5$

$$\frac{1}{4^5} = \frac{1}{1024} \approx 0.097\%$$

For  $q = 10$

$$\frac{1}{4^{10}} = \frac{1}{1048576} \approx 0.000095\%$$

For  $q = 20$

$$\frac{1}{4^{20}} = \frac{1}{1.09 \cdot 10^{12}} \approx 9.09 \cdot 10^{-11}\%$$

Med en populasjon på  $N = 5500000$  individer, blir forventet antall personer som har  $\mathcal{S}$  for de ulike verdiene av  $q$ .

For  $q = 5$

$$5500000 \cdot \frac{1}{4^5} = 5371.09$$

For  $q = 10$

$$5500000 \cdot \frac{1}{4^{10}} = 5.24$$

For  $q = 20$

$$5500000 \cdot \frac{1}{4^{20}} = 5.00 \cdot 10^{-6}$$

**b)** $A$  =Mistenkt er bidragsyter $B$  =Mistenkt har DNA-profil  $\mathcal{S}$ .

$P(B|A) = 1$  betyr med ord at mistenkt er bidragsyter gitt at mistenkt har DNA-profil  $\mathcal{S}$ . Vi har sett at selv med  $q = 5$  utvalgte posisjoner er sannsynligheten for at en enkeltperson sin DNA-profil er  $\mathcal{S}$  lik bare 0.097%. I forskning bruker man typisk  $p = 5\%$  som statistisk signifikant, og selv med en relativt god margin i en kriminalsak vil 0.097% være statistisk signifikant.

For  $P(B|A')$  vet vi fra tidligere at sannsynligheten for at vilkårlig person har en spesifikk DNA profil  $\mathcal{S}$  er lik

$$P(B|A') = \frac{1}{4^q}$$

**c)**

Skal finne  $P(A|B)$  gitt  $N = 5500000$  og  $q = 5, 10$  og  $20$ .

Kjenner til Bayes' formel

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Vet også følgende

$$P(A) = \frac{1}{N} = \frac{1}{5500000}, \quad P(B|A) = 1$$

$$P(A') = 1 - P(A) = \frac{N-1}{N}$$

$$P(B) = \frac{1}{N} + \frac{1}{4^q} \cdot \frac{N-1}{N} = \frac{1}{N} + \frac{N-1}{N \cdot 4^q}$$

Kan da sette inn i Bayes' formel

$$P(A|B) = \frac{\frac{1}{N}}{\frac{1}{N} + \frac{N-1}{N \cdot 4^q}} \cdot N \cdot 4^q = \frac{4^q}{4^q + (N-1)}$$

For  $q = 5$

$$P(A|B) = \frac{4^5}{4^5 + (5500000 - 1)} \approx 1.86 \cdot 10^{-4}$$

For  $q = 10$

$$P(A|B) = \frac{4^{10}}{4^{10} + (5500000 - 1)} \approx 0.1601$$

For  $q = 20$

$$P(A|B) = \frac{4^{20}}{4^{20} + (5500000 - 1)} \approx 0.9999$$

For  $q$  markører ser vi at sannsynligheten for at den mistenkte personen er en bidragsyter øker betraktelig. Fra nesten helt usannsynlig for  $q = 5$  til nesten helt garantert for  $q = 20$ .

**d)**

Definerer  $C$  = bidragsyter er et av individene i databasen. Videre er  $X$  antall personer med spor  $\mathcal{S}$  innen databasen.

Hvis  $C$  *ikke* har inntruffet vet vi at ingen personer i databasen har spor  $\mathcal{S}$ , og at den personen er en av de andre personene i  $N$  men ikke i  $n$ .

**e)**

**f)**

**g)**